

Análisis de Series de Tiempo II

Forecasting Probabilístico y Modelado de Incertidumbre

MSc. Fernando Silva



Agenda

- Repaso
- Chronos-2
- Del Punto a la Distribución
- Modelado de la Incertidumbre

Repaso

Repaso: Transformers

Modelo	Limitación que viene del anterior modelo	Cómo lo maneja
Vanilla Transformer		Self-attention completa entre timestamps
Informer	Impide horizontes largos. Inferencia paso a paso	ProbSparse, self-attention distilling, decoder generativo
Autoformer	Comparar puntos aislados no captura patrones; la tendencia tapa el ciclo	Auto-correlación por FFT y descomposición dentro de cada capa
Paper de DLinear	Bajo rendimiento de Informer y Autoformer por el manejo de tokens.	
TFT	El problema real tiene covariables estáticas/futuras, riesgo e interpretabilidad	VSN, GRN/GLU, atención interpretable y pinball loss (cuantiles)
PatchTST	La falla no era la atención sino la tokenización; el contexto era muy corto	Patching, channel independence, RevIN, pre-entrenamiento enmascarado

Repaso: Tres formas de mejorar al Transformer

- **Más rápido: SSM / Mamba**
 - En vez de mirar todo el pasado cada vez, van guardand un "resumen" que actualizan paso a paso.
 - **Más simple: DLinear, TSMixer**
 - Resultó que modelos mucho más sencillos ganaban.
 - El problema no era la capacidad, era cómo se partía la serie en pedazos.
 - **Más general: Chronos-2, TS-RAG**
 - Un modelo entrenado con miles de series, que anda en una serie nueva sin entrenar.
- Los tres tienen algo en común, la respuesta es un número.

Chronos-2



Chronos-2

- Modelo del curso cuya salida nativa no es un punto sino 21 cuantiles simultáneos.
- **Chronos "1"** discretizaba la serie en tokens y la trataba como lenguaje. **Chronos-Bolt** eliminó la tokenización a favor de parches. **Chronos-2** añade multivariado, covariables y cross-learning.
- El paso de tokenización a parches es exactamente la idea de PatchTST.

Chronos-2

- Chronos-2 es MIMO puro: emite el horizonte completo de una vez, sin realimentación.
- Chronos-2 atiende conjuntamente a las series del panel en tiempo de inferencia. El panel es contexto, no dato de entrenamiento.
- Las covariables futuras conocidas se tratan como series adicionales dentro del mismo mecanismo de atención, no como un regresor externo pegado al final.

Chronos-2



Chronos-2

[LINK](#)



Chronos-2 para Pasajeros de Aerolineas

[LINK](#)



Del Punto a la Distribución

Ejemplo


- Hay que decidir cada mañana cuántos panes hornear.
 - **Si horneamos de menos:** clientes que se van a la competencia.
 - **Si horneamos de más:** pan que se tira a la noche.
- Sabemos cuánto vendimos cada día del último año.
- El modelo de la clase pasada predice: "mañana, 300 panes".
- Tres preguntas que este número no responde:
 - ¿Cuánto me puedo desviar? ¿300 o 310? ¿300 o 500?
 - ¿Qué chance hay de que necesite más de 400?
 - ¿Cuántas hornear?
 - La respuesta casi nunca es 300.
- Veremos cómo pasar de "300" a un pronóstico que responde las tres.



Forecasting Probabilístico

- **Antes:**

- Mañana vendo 300 panes.



- **Ahora:**

- Lo más probable es 300.
 - 8 de cada 10 días voy a estar entre 240 y 380.
 - Es muy raro que pase de 450.
 - Casi nunca bajo de 200.
- Lo segundo contiene a lo primero, y agrega todo lo que hace falta para decidir.
 - Tres formas de realizar esto.

Forecasting Probabilístico

- Tres formas de realizar esto:
 - Describirlo con pocos números (DeepAR):
 - "Es una campana centrada en 300, que se abre unos 60."
 - Barato y ordenado.
 - Problema: si la realidad no tiene forma de campana (por ejemplo, los sábados venden el doble y entonces hay dos picos), el modelo no lo puede decir.
 - Dar varios cuantiles (Chronos-2, TFT):
 - "Nivel 10 es 240. Nivel 50 es 300. Nivel 90 es 380."
 - No asume ninguna forma. Es lo más usado hoy.
 - Problema: solo sabés lo que preguntaste.
 - Dar muchos futuros posibles (MC Dropout, ensembles):
 - "Acá tienes 500 escenarios de cómo puede venir mañana."
 - Lo más flexible: puede tener dos picos, colas raras, lo que sea.
 - Problema: caro de calcular.

Forecasting Probabilístico

- La panadería vende, en promedio, 300 panes por día ¿cuántos horneamos?
- Si sobra y falta duelen igual. Entonces hornearemos 300 (esto es lo que el MAE optimiza).
- Si faltar duele más (el cliente se va y no vuelve). Entonces hornearemos 380. El nivel 90.
- Si sobrar duele más (el pan del día se tira entero). Entonces hornearemos 250. El nivel 20.
- Los tres casos, el mismo modelo, la misma serie. Tres respuestas distintas.
- No existe "el mejor pronóstico". Existe el mejor pronóstico para una decisión.
- Por eso, decir "el modelo predice 300" sin decir para qué se va a usar es una respuesta incompleta.

Del punto a la distribución

[LINK](#)



Intervalos de Predicción

Ruido

Lo que nadie puede saber

- Cuánta gente entra hoy tiene una parte de puro azar. Que llueva, que alguien pase de casualidad.
- Más datos no lo reducen.
- Como tirar un dado: podemos tirarlo un millón de veces y seguimos sin saber la próxima.
- El modelo tiene que representarlo, no eliminarlo

Ignorancia

Lo que el modelo no aprendió

- Nunca vio un feriado largo. No saber qué pasa.
- Más datos si lo reducen
- Como un dado con caras que no vimos: tirándolo más, vamos aprendiendo cómo es.
- Crece mucho cuando le pedimos algo que nunca vio

Algo propio de series de tiempo es que la incertidumbre crece con el horizonte.

Quantile Forecasting

La idea es penalizar más al modelo por errar para un lado que para el otro.

Ejemplo:

- Queremos que el modelo aprenda el nivel 90, le penalizamos de la siguiente manera:
 - Predijo 300, la realidad fue 400, se quedó corto por 100.

$$\text{penalización} = 100 \times 0.9 = 90$$

- Predijo 300, la realidad fue 200, se pasó por 100

$$\text{castigo} = 100 \times 0.1 = 10$$

$$L_{\alpha}(y, \hat{y}) = \begin{cases} \alpha \cdot (y - \hat{y}) & \text{if } y \geq \hat{y} \\ (\alpha - 1) \cdot (y - \hat{y}) & \text{if } y < \hat{y} \end{cases}$$

Quedarse corto sale 9 veces más caro que pasarse.

Esto hace que el modelo se acomode hacia arriba, hasta que la realidad queda por debajo de su predicción 9 de cada 10 veces. Esto es el nivel 90. Esta forma de penalizar se llama **Pinball Loss**

Si la penalización es igual para los dos lados (mitad y mitad), el modelo aprende la mediana. Y eso es exactamente entrenar con MAE.

Una sola red con 9 salidas y esta penalización sumada aprende los 9 niveles de una sola vez, en un solo entrenamiento. Un error común es entrenar un modelo por cada nivel. No hace falta, y es 9 veces más caro.

Quantile Crossing

- Cuando los niveles se dan vuelta pasa esto:

- nivel 10: 320 panes
- nivel 50: 300 panes
- nivel 90: 380 panes



El nivel 10 quedó por arriba de la mediana. Es imposible, el nivel 10 es "el valor que superó solo 1 de cada 10 veces". No puede ser mayor que el del medio.

- ¿Por qué pasa? Las 9 salidas de la red son independientes. Nada las obliga a salir ordenadas. Cada una aprende por su cuenta.
- Pasa más en horizontes largos y en los niveles extremos (el 5, el 95).

Tres arreglos:


- **Ordenarlos:** con una línea como sorted(salidas).
- **Cambiar la arquitectura:** que la red prediga la mediana, y después solo "cuánto más" para cada nivel siguiente, obligando a que ese "cuánto más" sea positivo. Así no se pueden cruzar nunca.
- **Penalizar en el entrenamiento:** agregar un castigo cuando se cruzan.

Si el modelo cruza mucho puede ser que hay pocos datos o un horizonte más largo del que la serie soporta.


Modelado de la Incertidumbre

Monte Carlo Dropout

- **Dropout:** durante el entrenamiento apagamos neuronas al azar para que la red no se sobreajuste. En producción usamos la red completa.



(a) Standard Neural Net



(b) After applying dropout.

- **MC Dropout:** dejamos prendido en producción. Corremos la predicción 100 veces. Cada vez se apagan neuronas distintas, así que cada vez da un número distinto:

302, 298, 311, 295, 304, 299, 308, ... ***todas parecidas: el modelo está seguro***

280, 410, 190, 350, 220, 480, 300, ... ***todas distintas: el modelo no tiene idea***

La dispersión entre las 100 corridas es la medida de incertidumbre.

- **Ejemplo:**
 - Es como preguntarle lo mismo a 100 versiones ligeramente distintas del mismo panadero. Si todos dicen 300, confiamos. Si uno dice 190 y otro 480, algo no está claro.

Monte Carlo Dropout

MC Dropout mide desacuerdo, no el ruido.

- Si el día de mañana es intrínsecamente impredecible pero las 100 corridas están todas de acuerdo, MC Dropout te devuelve un rango angosto y equivocado.
- La solución es que la red devuelva dos cosas: la predicción y cuánto ruido espera para ese día.
- La tasa de dropout la elegimos para regularizar, no para medir incertidumbre. Si la subimos de 0.1 a 0.3, los rangos se ensanchan.
- La incertidumbre que te da MC Dropout está en una escala arbitraria. Sirve para comparar no como rango confiable.

Incertidumbre total = ruido esperado (lo que nadie puede saber) + desacuerdo (lo que el modelo no aprendió)

Forecasting Bayesiano

- Una red normal aprende un valor para cada peso.

$$\text{peso}_{47} = 0.73$$

- Una red bayesiana aprende un rango para cada peso.

$$\text{peso}_{47} = \text{alrededor de } 0.73, \text{ más o menos } 0.2$$

- Para predecir, en vez de usar un solo juego de pesos, promediamos sobre todos los juegos posibles.
- Idea: tener miles de redes y consultarlas a todas. Si todas coinciden es seguridad. Si difieren es incertidumbre.
- Ese promedio sobre "todos los pesos posibles" es imposible de calcular exacto. Todo lo bayesiano en deep learning es alguna forma de aproximarlos:

MCMC: exacto,
impagable

Variacional:
rápido, con sesgo

MC Dropout: resulta
ser bayesiano

Deep Ensembles:
la que mejor va

- Lo que si aporta ser bayesiano en series de tiempo: **Podemos meter lo que ya sabemos antes de ver los datos.** Las ventas cambian de a poco, no a los saltos. Hay un patrón semanal. **Y si lo que "sabías" estaba mal, el modelo te da rangos muy seguros y muy equivocados.**

CRPS

Una métrica para la distribución entera

- El MAE mide qué tan lejos estuvo el número de la realidad.
- El CRPS mide qué tan lejos estuvo la distribución de la realidad.
 - "CRPS = 32" se lee igual que un MAE de 32.
 - Si la distribución es un solo número, el CRPS es el MAE.
 - El CRPS es la pinball loss promediada sobre todos los niveles.
- Ejemplo:
 - Si tenemos 9 niveles, calculamos la pinball de cada uno, promediamos, y multiplicamos por dos. Eso es el CRPS.

Conformal Prediction

Veníamos con un problema:

- MC Dropout te da rangos en escala arbitraria
- Bayesiano no garantiza que sean honestos
- Los niveles aprendidos se descalibran cuando algo cambia

Conformal da rangos honestos con garantía y no supone nada: ni sobre el modelo, ni sobre los datos.

En vez de creerle al modelo cuando dice cuánta incertidumbre tiene, mirá cuánto se equivocó históricamente y usá eso.

Conformal Prediction

Algoritmo:

1. Apartamos un pedazo de datos que el modelo no vea. Llamémoslo "el set de calibración".
2. Entrenamos el modelo que queremos. Cualquiera: LSTM, Chronos-2, un promedio móvil.
3. En el set de calibración, anotamos cuánto se equivocó en cada punto:
 $|\text{lo real} - \text{lo predicho}|$
4. Ordenamos esos errores y buscamos el que está en la posición 90%. Digamos que da 85.
5. El rango al 90% es:
 $\text{predicción} - 85 \quad \text{hasta} \quad \text{predicción} + 85$

Si históricamente 9 de cada 10 veces te equivocaste por menos de 85 panes, es razonable esperar que la próxima también.

Resumen

[LINK](#)

