

Análisis de Series de Tiempo II

Forecasting en Producción y Sistemas Reales

MSc. Fernando Silva





Agenda

- Repaso
- Time Series RAG
- Time Series Fine-tuning
- Pipelines Temporales y Serving

Repaso

Chronos-2



Quantile Forecasting

La idea es penalizar más al modelo por errar para un lado que para el otro.

Ejemplo:

- Queremos que el modelo aprenda el nivel 90, le penalizamos de la siguiente manera:
 - Predijo 300, la realidad fue 400, se quedó corto por 100.

$$\text{penalización} = 100 \times 0.9 = 90$$

- Predijo 300, la realidad fue 200, se pasó por 100

$$\text{castigo} = 100 \times 0.1 = 10$$

$$L_{\alpha}(y, \hat{y}) = \begin{cases} \alpha \cdot (y - \hat{y}) & \text{if } y \geq \hat{y} \\ (\alpha - 1) \cdot (y - \hat{y}) & \text{if } y < \hat{y} \end{cases}$$

Quedarse corto sale 9 veces más caro que pasarse.

Esto hace que el modelo se acomode hacia arriba, hasta que la realidad queda por debajo de su predicción 9 de cada 10 veces. Esto es el nivel 90. Esta forma de penalizar se llama **Pinball Loss**

Si la penalización es igual para los dos lados (mitad y mitad), el modelo aprende la mediana. Y eso es exactamente entrenar con MAE.

Una sola red con 9 salidas y esta penalización sumada aprende los 9 niveles de una sola vez, en un solo entrenamiento. Un error común es entrenar un modelo por cada nivel. No hace falta, y es 9 veces más caro.

Quantile Crossing

- Cuando los niveles se dan vuelta pasa esto:

- nivel 10: 320 panes
- nivel 50: 300 panes
- nivel 90: 380 panes



El nivel 10 quedó por arriba de la mediana. Es imposible, el nivel 10 es "el valor que superó solo 1 de cada 10 veces". No puede ser mayor que el del medio.

- ¿Por qué pasa? Las 9 salidas de la red son independientes. Nada las obliga a salir ordenadas. Cada una aprende por su cuenta.
- Pasa más en horizontes largos y en los niveles extremos (el 5, el 95).


Tres arreglos:

- **Ordenarlos:** con una línea como sorted(salidas).
- **Cambiar la arquitectura:** que la red prediga la mediana, y después solo "cuánto más" para cada nivel siguiente, obligando a que ese "cuánto más" sea positivo. Así no se pueden cruzar nunca.
- **Penalizar en el entrenamiento:** agregar un castigo cuando se cruzan.


Si el modelo cruza mucho puede ser que hay pocos datos o un horizonte más largo del que la serie soporta.

Monte Carlo Dropout

- **Dropout:** durante el entrenamiento apagamos neuronas al azar para que la red no se sobreajuste. En producción usamos la red completa.



(a) Standard Neural Net



(b) After applying dropout.

- **MC Dropout:** dejamos prendido en producción. Corremos la predicción 100 veces. Cada vez se apagan neuronas distintas, así que cada vez da un número distinto:

302, 298, 311, 295, 304, 299, 308, ... ***todas parecidas: el modelo está seguro***

280, 410, 190, 350, 220, 480, 300, ... ***todas distintas: el modelo no tiene idea***

La dispersión entre las 100 corridas es la medida de incertidumbre.

- **Ejemplo:**
 - Es como preguntarle lo mismo a 100 versiones ligeramente distintas del mismo panadero. Si todos dicen 300, confiamos. Si uno dice 190 y otro 480, algo no está claro.

CRPS


Una métrica para la distribución entera

- El MAE mide qué tan lejos estuvo el número de la realidad.
- El CRPS mide qué tan lejos estuvo la distribución de la realidad.
 - "CRPS = 32" se lee igual que un MAE de 32.
 - Si la distribución es un solo número, el CRPS es el MAE.
 - El CRPS es la pinball loss promediada sobre todos los niveles.
- Ejemplo:
 - Si tenemos 9 niveles, calculamos la pinball de cada uno, promediamos, y multiplicamos por dos. Eso es el CRPS.

Time Series RAG

Time Series RAG

RAG (Retrieval-Augmented Generation) en texto busca documentos parecidos a una pregunta y los usa como base para redactar la respuesta. La misma idea funciona con series de tiempo: en vez de documentos, buscamos ventanas históricas parecidas a la situación actual.




Time Series RAG

RAG

RAG (Retrieval-Augmented Generation) en texto busca documentos parecidos a una pregunta y los usa como base para redactar la respuesta. La misma idea funciona con series de tiempo: en vez de documentos, buscamos ventanas históricas parecidas a la situación actual.

Paso del proceso	RAG de texto	RAG de series de tiempo
Base de conocimiento	Documentos / párrafos	Ventanas históricas de la serie
Representación	Embedding del texto	Ventana normalizada (su forma)
Búsqueda (retrieval)	Similitud entre significados	Similitud entre patrones/curvas
Generación	LLM redacta una respuesta	Promedio de análogos

Time Series RAG



Time Series RAG


[LINK](#)



Time Series RAG

Chronos-Bolt

Timeline of TSFM Releases (2023-2026)



TS RAG con Chronos-Bolt


[LINK](#)



Time Series Fine-tuning

Time Series Fine-tuning

Catastrophic Forgetting



Time Series Fine-tuning

[LINK](#)

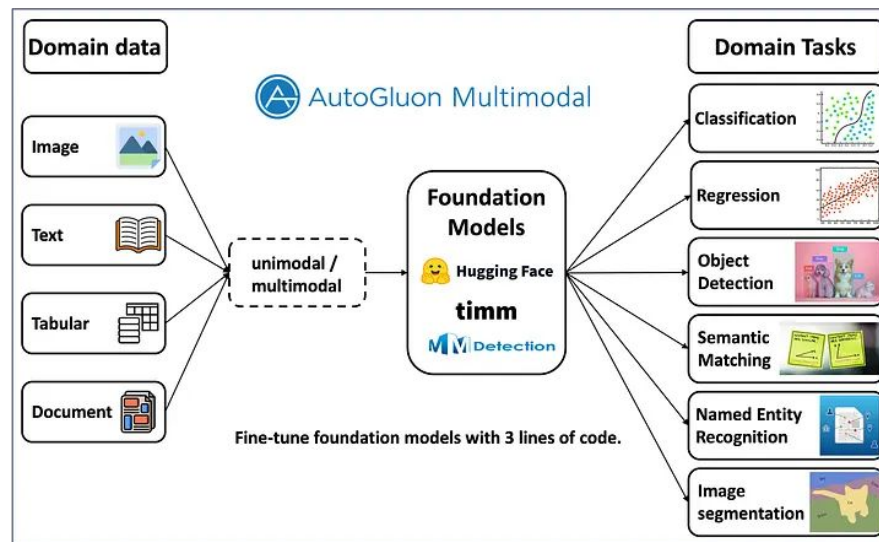


Time Series Fine-tuning

AutoGluon

El fine-tuning de modelos fundacionales de series de tiempo puede realizarse a través de AutoGluon TimeSeries, que expone los modelos Chronos y Chronos-2 como estimadores dentro de TimeSeriesPredictor.

- AutoGluon expone Chronos y Chronos-2 como modelos de TimeSeriesPredictor.
- `fine_tune=True` dispara el ajuste (LoRA) implementado en la librería Chronos; AutoGluon orquesta datos, validación temporal, entrenamiento y evaluación.



TS Fine-tuning con Chronos

[LINK](#)



Ejercicio Resuelto, TS Fine-tuning con Chronos

[LINK](#)



Pipelines Temporales y Serving

Pipelines Temporales y Serving

[LINK](#)

